



MIAD

Maestría
en Inteligencia
Analítica de Datos



Taller - Data Version Control - DVC

La entrega de este taller consiste en un reporte y unos archivos de soporte. Cree el archivo de su reporte como un documento de texto en el que pueda fácilmente incorporar capturas de pantalla, textos y similares. Puede ser un archivo de word, libre office, markdown, entre otros.

DVC es una herramienta complementaria a Git que permite gestionar y versionar datos y modelos de aprendizaje automático en proyectos de ciencia de datos. Es independiente del lenguaje o framework, lo que la hace versátil y adecuada para cualquier proyecto de *Machine Learning*. Con DVC, los equipos pueden mantener un control completo sobre sus datos y modelos, asegurando transparencia, reproducibilidad y colaboración efectiva en el desarrollo de sus proyectos.

Antes de empezar

En esta actividad necesitamos las credenciales de AWS para realizar algunas operaciones. En AWS Academy, inicie el Laboratorio de aprendizaje. En el menú de la esquina superior derecha encontrará el ítem AWS Details. Allí se encuentra el ítem AWS CLI, de click en Show. Copie los datos de conexión que allí aparecen: `aws_access_key_id`, `aws_secret_access_key` y `aws_session_token`. Guárdelos en un archivo de texto para usarlos más adelante.

Instale DVC

1. En su espacio de AWS Academy ingrese a la consola de EC2 y lance una instancia con las siguientes características:
 - a) Nombre: Asigne un nombre adecuado.
 - b) Imagen (Amazon Machine Image - AMI): Ubuntu Server 24.04 LTS (HVM), SSD Volume Type (id: `ami-0a0e5d9c7acc336f1`).
 - c) Tipo de instancia: `t2.micro` (apta para la capa gratuita).
 - d) Par de claves: Cree un nuevo par de claves o reutilice uno previamente guardado. De ahora en adelante nos referiremos a la llave como *llave.pem*.



- e) Configuración de red: valores por defecto (esto creará un grupo de seguridad con permisos de conexión por SSH, puerto 22).
 - f) Almacenamiento: 10 GB de disco.
2. Conéctese a la máquina:
- a) Abra una terminal: En windows, escriba `cmd` y `Enter`. En macOS, abra la aplicación llamada *Terminal*.
 - b) En la terminal emita el comando

```
ssh -i /path/to/llave.pem ubuntu@IP
```

donde `/path/to/` se refiere a la ubicación del archivo `llave.pem` que descargó, e `IP` es la dirección IP de la instancia EC2 que lanzó. Si prefiere, en la terminal puede navegar a la ubicación del archivo `llave.pem` y emitir el comando

```
ssh -i llave.pem ubuntu@IP
```
- Asegúrese de incluir en su reporte un *screenshot* de la conexión a la máquina virtual.**
3. Verifique que tiene python 3 instalado.
- ```
python3 --version
```
4. Actualice la lista de paquetes del sistema ejecutando el siguiente comando:
- ```
sudo apt update
```
5. Instale pip.
- ```
sudo apt install python3-pip
```
- Verifique su instalación
- ```
pip --version
```
6. Instale venv para crear ambientes virtuales. En la versión 3.12 para Ubuntu/Debian puede usar el comando
- ```
sudo apt install python3.12-venv
```
7. Cree un ambiente virtual con nombre `env-dvc`
- ```
python3 -m venv /home/ubuntu/env-dvc
```
8. Active el ambiente con el comando
- ```
source env-dvc/bin/activate
```



y con el ambiente activo instale dvc con dependencias para administrar el almacenamiento remoto de datos en AWS S3.

```
pip install "dvc[s3]"
```

Otras opciones para el almacenamiento remoto son [gdrive], [gs], [azure], [ssh], [hdfs], [webdav], [oss] o [all] para instalarlos todos.

9. Verifique que cuenta con Git

```
git --version
```

10. Para Windows existe un instalador en <https://dvc.org/doc/install/windows>. Allí también hay instrucciones para instalarlo con Conda.

## Un primer proyecto en DVC

1. En la terminal asegúrese de estar en el home (`cd ~`) y cree una carpeta para su proyecto

```
mkdir dvc-proj
```

2. Ingrese a la carpeta del proyecto

```
cd dvc-proj
```

e inicie un repositorio de Git

```
git init
```

Asegúrese de que la rama actual quede nombrada como main

```
git branch -m main
```

3. En la misma carpeta inicialice el repositorio de DVC

```
dvc init
```

4. Note que se han creado algunos archivos en la carpeta

```
git status
```

Para agregarlos al repositorio de Git realice un commit

```
git commit -m "Inicializacion de DVC"
```

5. Cree una subcarpeta data y agregue el dataset iris.csv a dicha subcarpeta con el nombre data.csv

```
mkdir -p data && curl https://gist.githubusercontent.com/netj/8836201/raw/6f9306ad21398ea43cba4f7d537619d0e07d5ae3/iris.csv -o data/data.csv
```



6. Agregue el archivo de datos descargado al repositorio dvc

```
dvc add data/data.csv
```

7. Note que en la subcarpeta data se han creado varios archivos, entre ellos uno con extensión .dvc que permite llevar el registro de los cambios al archivo de datos en git, así como un .gitignore para ignorar el archivo de datos. Explore estos archivos e incluya pantallazos en su **reporte**. Para listar los archivos en la subcarpeta data puede usar

```
ls data
```

o

```
ls -la data
```

Para listar el contenido de un archivo puede usar por ejemplo

```
cat data/.gitignore
```

8. Agregue los archivos de registro al repositorio Git con el comando

```
git add data
```

y haga el commit asociado

```
git commit -m "Primera version de los datos"
```

Note que unicamente los archivos data/data.csv.dvc y data/.gitignore son adicionados.

9. Cree un repositorio de GitHub remoto y envíe los cambios locales, siguiendo estos pasos:

- Vaya a GitHub (<https://github.com/>) e inicia sesión en tu cuenta.
- Haga clic en el botón “New” (Nuevo) en la parte superior izquierda de la página de inicio.
- Complete el nombre del repositorio, una breve descripción y configure otras opciones según sus preferencias.
- Opcionalmente, puede agregar un archivo README o un archivo .gitignore durante la creación del repositorio.
- Haga clic en el botón “Create repository” (Crear repositorio) para crear el repositorio remoto.
- Conectar el repositorio local con el remoto:
  - Copie la URL del repositorio remoto que creó en GitHub.
  - Ejecute el siguiente comando en la terminal para vincular el repositorio local con el remoto:

```
git remote add origin https://github.com/usuario/nombre_repo.git
```

- g) Enviar los cambios locales al repositorio remoto:

```
git push -u origin main
```



En consola, recibirás un mensaje solicitando tu usuario en github:

```
Username for 'https://github.com':
```

Este mensaje solicita que ingrese su nombre de usuario de GitHub para autenticar tus operaciones Git cuando interactúa con el repositorio remoto a través del protocolo HTTPS.

Posteriormente, le solicitará la contraseña de su cuenta en github:

```
Password for 'https://user@github.com':
```

Sin embargo, el soporte para la autenticación con contraseña fue eliminado a partir del 13 de agosto de 2021. Ahora, en lugar de usar una contraseña, deberá generar un token de acceso para poder acceder a su cuenta.

Para esto, debe seguir los siguientes pasos:

- 1) En github, vaya a *settings*
- 2) *Developer settings*
- 3) *Personal access token*
- 4) *Tokens (classic)*
- 5) *Generate new token (classic)*
- 6) Asigne un nombre
- 7) Defina una duración
- 8) Seleccione “repo”

### New personal access token (classic)

Personal access tokens (classic) function like ordinary OAuth access tokens. They can be used instead of a password for Git over HTTPS, or can be used to [authenticate to the API over Basic Authentication](#).

#### Note

Prueba

What's this token for?

#### Expiration \*

30 days

The token will expire on Tue, Aug 22 2023

#### Select scopes

Scopes define the access for personal tokens. [Read more about OAuth scopes](#).

|                                                     |                                                |
|-----------------------------------------------------|------------------------------------------------|
| <input checked="" type="checkbox"/> <b>repo</b>     | Full control of private repositories           |
| <input checked="" type="checkbox"/> repo:status     | Access commit status                           |
| <input checked="" type="checkbox"/> repo_deployment | Access deployment status                       |
| <input checked="" type="checkbox"/> public_repo     | Access public repositories                     |
| <input checked="" type="checkbox"/> repo:invite     | Access repository invitations                  |
| <input checked="" type="checkbox"/> security_events | Read and write security events                 |
| <input type="checkbox"/> <b>workflow</b>            | Update GitHub Action workflows                 |
| <input type="checkbox"/> <b>write:packages</b>      | Upload packages to GitHub Package Registry     |
| <input type="checkbox"/> read:packages              | Download packages from GitHub Package Registry |
| <input type="checkbox"/> <b>delete:packages</b>     | Delete packages from GitHub Package Registry   |



9) Click en *Generate token*

10) Copie el *token*

Si le solicita contraseña, ingrese el token.

**Incluya en su reporte el link del repositorio y un *screenshot* de su repositorio con el archivo *.csv.dvc*.**

## Gestionando datos con fuente local

Con DVC podemos contar con diversas fuentes de datos, llamados remotes. Para empezar configuremos y usemos una fuente local.

1. En el directorio `/tmp` cree una carpeta para almacenar los datos

```
mkdir /tmp/dvcstore
```

2. Desde la carpeta del proyecto de DVC creada anteriormente (`cd ~/dvc-proj`) agregue esta fuente local con nombre `fuentelocal`

```
dvc remote add -d fuentelocal /tmp/dvcstore
```

Note que esta fuente queda listada en `.dvc/config` y es definida como la fuente por defecto.

```
cat .dvc/config
```

3. Haga un push de DVC para actualizar los datos en la fuente por defecto creada

```
dvc push
```

4. Explore el contenido de la carpeta `/tmp/dvcstore/` y observe que se ha agregado información sobre los datos registrados por DVC.

5. Volviendo a su carpeta de proyecto (`cd ~/dvc-proj`), haga una prueba eliminando los datos del caché y de la carpeta `data` con los comandos

```
rm -rf .dvc/cache/
```

```
rm -f data/data.csv
```

Verifique que los datos se han eliminado con

```
ls data
```

que no debe mostrar el archivo `data.csv`. Ahora, realice un pull, para traer los datos a partir de la fuente remota



```
dvc pull
```

y observe nuevamente el contenido de la carpeta data, verificando que el archivo data.csv se encuentra disponible.

## Conexión con S3

En lugar de una fuente local, podríamos establecer como almacenamiento remoto un servicio en la nube, como S3.

1. Asegúrese de tener la última versión de OpenSSL

```
pip install pyopenssl --upgrade
```

2. Copie localmente los instaladores de la interfaz de línea de comandos de AWS (CLI)

```
curl "https://awscli.amazonaws.com/awscli-exe-linux-x86_64.zip" -o ~/awscliv2.zip
```

3. Descomprima el archivo y ejecute el instalador

```
sudo apt install unzip
```

```
unzip ~/awscliv2.zip -d ~/
```

```
sudo ~/aws/install
```

4. Verifique la versión de AWS CLI

```
aws --version
```

5. Configure la llave de acceso y la llave secreta de AWS con el comando

```
aws configure
```

el cual le solicitará el AWS Access Key y el AWS Secret Access Key, los cuales copió al inicio del taller. También se solicita Region, donde debe especificar us-east-1. Finalmente le pide *Default output format*, el cuál puede saltar con un enter.

6. Configure ahora el token de la sesión con el comando

```
aws configure set aws_session_token SESSIONTOKEN
```

reemplazando SESSIONTOKEN por el token que copió al inicio del taller.

7. Verifique que su cuenta quedó bien configurada solicitando el listado de usuarios de IAM

```
aws iam list-users
```





que debe retornar un listado vacío en formato JSON.

8. Cree un bucket de S3. Recuerde que el nombre asignado debe ser único, entonces podría usar algo como sunombre-dvcstore

```
aws s3 mb s3://sunombre-dvcstore
```

Alternativamente al comando anterior, podría crear el bucket desde la consola de AWS, buscando el servicio S3 y seleccionando Buckets en el menú de la izquierda, para posteriormente hacer click en Crear bucket.

9. Agregue el bucket creado como un remote en dvc, estableciéndolo como default, con

```
dvc remote add -d aws-remote s3://sunombre-dvcstore
```

Incluya en su reporte un *screenshot* del contenido del archivo `.dvc/config`, donde se evidencien los dos remotes (local y S3).

10. Ahora puede enviar los datos al remote de dvc

```
dvc push
```

11. En el bucket de S3 revise que se encuentren los archivos.

12. Realice un commit para agregar al repositorio de git la modificación de `.dvc/config`

```
git commit .dvc/config -m "Adicionar S3 como remote"
```

## Trabajando con una nueva versión de los datos

1. Suponga ahora que se crean nuevos datos, lo cual puede simular duplicando los datos con los comandos

```
cp data/data.csv /tmp/data.csv
```

```
cat /tmp/data.csv >> data/data.csv
```

2. Ahora agregue el archivo actualizado al registro de DVC

```
dvc add data/data.csv
```

y envíelo al repositorio de DVC con el comando

```
dvc push
```

3. Ahora, agregue los cambios al repositorio de Git haciendo un commit

```
git commit data/data.csv.dvc -m "Dataset actualizado"
```



Y envíelos al repositorio remoto

```
git push -u origin main
```

Incluya en su reporte un *screenshot* del identificador md5 del archivo `.csv`.

```
cat data/data.csv.dvc
```

e incluya un *screenshot* que evidencie que hay 2 objetos dentro de la carpeta `files/md5/` en su bucket de S3 (los identificadores de las versiones creadas).

4. Clone el repositorio que creó en una nueva carpeta, para esto vuelva a la carpeta principal:

```
cd ~
```

Luego, clone el repositorio con el siguiente comando:

```
git clone https://github.com/usuario/nombre_repo.git
```

E ingrese a la carpeta creada

```
cd nombre_repo
```

Note que en la subcarpeta `data`, no tiene el archivo de datos `.csv`

5. Obtenga los datos del remote con

```
dvc pull
```

Incluya en su reporte un *screenshot* del repositorio clonado correctamente en otra carpeta.

## Git y dvc checkout

Finalmente, en ocasiones es útil crear ramas en el repositorio de git. Lo anterior, permite la gestión y desarrollo colaborativo de proyectos de forma más eficiente y segura pues las ramas permiten:

1. **Desarrollo independiente:** Permite a los desarrolladores trabajar en diferentes características, correcciones de errores o mejoras en paralelo sin interferir entre sí. Cada rama es una línea de desarrollo independiente, lo que facilita la colaboración en proyectos con múltiples colaboradores.
2. **Aislamiento de cambios:** Cuando se trabaja en una rama, los cambios que se realizan no afectan directamente al código en otras ramas. Esto ofrece un entorno seguro para probar nuevas ideas o implementaciones sin afectar la estabilidad del código en la rama principal o en otras ramas.
3. **Control de versiones:** Cada rama tiene su propio historial de cambios y versiones, lo que permite a los desarrolladores revisar, comparar y volver atrás en el tiempo para entender cómo evolucionó el código en cada línea de desarrollo.



4. **Pull Requests:** Las ramas son fundamentales para el flujo de trabajo de Pull Requests en GitHub. Los desarrolladores crean nuevas ramas para agregar nuevas características o solucionar problemas, y luego envían Pull Requests para fusionar sus cambios en la rama principal (por lo general, la rama "main" o "master"). Los Pull Requests permiten una revisión y discusión antes de que los cambios se incorporen al proyecto principal.
5. **Experimentación y pruebas:** Las ramas proporcionan un entorno aislado para experimentar con cambios importantes en el código sin comprometer la estabilidad del proyecto principal. Una vez que los cambios se prueban y validan en la rama, se pueden fusionar en la rama principal. **Versiones estables:** Al mantener una rama principal estable, es posible garantizar que siempre exista una versión funcional y utilizable del proyecto. Las nuevas características se desarrollan en ramas separadas, lo que ayuda a evitar la introducción de errores críticos en la rama principal.

Para crear una nueva rama y cambiar a ella, simplemente emita el siguiente comando en la terminal:

```
git checkout -b nombre_rama
```

Esto creará una nueva rama llamada **nombre\_rama** y lo cambiará automáticamente a esa nueva rama.

Asimismo, el comando `dvc checkout` se utiliza generalmente después de realizar un `git checkout`, `git clone` o cualquier otra operación que cambie los archivos `dvc.lock` o `.dvc` actuales en el proyecto. Este comando restaura las versiones correspondientes de todos los archivos y directorios de datos rastreados por DVC desde el caché al espacio de trabajo para descargar los datos y modelos que están versionados en DVC, pero que aún no están presentes en la copia local del repositorio. Esto es útil cuando usted está trabajando en un proyecto en equipo y otros colaboradores han versionado cambios en los datos o modelos. Al ejecutar `dvc checkout`, se asegura de tener las últimas versiones de los datos y modelos que aún no tiene en su copia local del repositorio.

En general, al cambiar a una nueva rama debe emitir los siguientes comandos:

```
git checkout nombre_rama
dvc checkout
```

Incluya en su reporte un *screenshot* realizando una exploración de los comandos anteriores.